BERT

BERT是一种预训练语言表示的方法，这意味着我们在大型文本语料库（例如Wikipedia）上训练通用的“语言理解”模型，然后将该模型用于我们关心的下游NLP任务（例如问题回答）。 BERT优于以前的方法，因为它是第一个用于预训练NLP的无监督，深度双向系统。

1、基本概念

> **BERT基本组成**为Seq2Seq网络：输入和输出都为序列的网络，中间为Transformer

为什么要Transformer? 因为传统RNN网络每个循环体都需要上一个循环体的中间结果，无法并行运算（不独立）；采用Self-Attention机制并行计算，取代RNN

为什么不用word2vec? 相同的词表达含义一样，实际上不是这样的

Self-Attention机制：在不同的语境下不同的词有不同的权重。

方法：词->向量编码x1->权重向量编码z1

预先定义三个矩阵（权重）Wq、Wk、Wv，分别表示要被查询的、等待被查的和实际的特征信息，使输入词向量分别与三个矩阵进行运算。然后用softmax来进行归一化，求得每个词在当前句子中占有的权重（影响程度）

若要查询第一个词与每个词的关系，则用Wq1*Wk1（内积：若无关系则内积为0）表示与第一个词的关系，Wq1*Wk2表示与第二个词的关系，以此类推

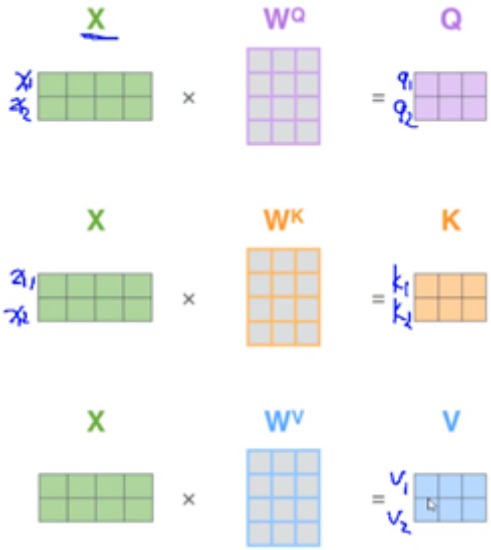

Multi-headed机制：提取多种词向量特征（上述只是提取一种特征）

通过多个头机制（一般8个）得到多个特征表达，然后将所有特征拼接起来，再加一层全连接来降维

注：通过上述过程得到词特征向量，一般情况下还要堆叠多层来得到最终的词特征向量

位置信息表达：相对于上述得到的词特征向量再加上位置信息编码，一般是周期信号（正余弦等）

LayerNormalize：对每个词的所有特征进行归一化处理（区别于对每批数据进行归一化），为了使得训练更快，更稳定。其中词的特征向量由上述处理得到

连接：层归一化的同时，加入残差连接

Decoder：相对于Encoder，Self-Attention计算不同（用q来查），加入了MASK机制。

训练BERT：将句子中15%（替换为mask，随机变为其他词或不变）的词随机mask掉，让模型去预测被mask的是什么；预测两个句子是否应该连在一起（[seq]连接符，[cls]分类向量）

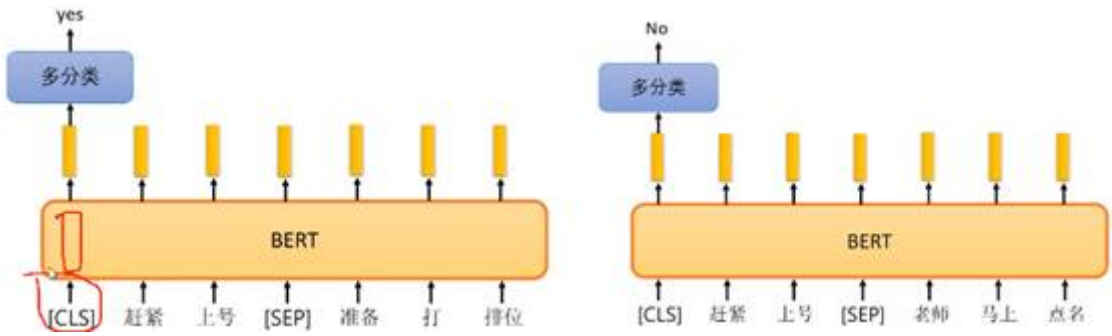

2、源码简介

数据:

1、加载数据（一般是两句话或一句话）==> 按模板格式化数据 + 定义标签

2、制作TF_record格式数据集==> 制作label字典（label：index） + 数据分词 + 数据补全（并加CLS等标识符） + 词典查ID（同时设置input_mask，作用是指示哪些位置的词是有效的） + 段标识符（用来指示这是第几个话，0/1表示。最后用0补全长度）

```
546     # 生成tf_record文件
547     writer = tf.python_io.TFRecordWriter(output_file)
548
549     # 遍历每一条数据
550     for (ex_index, example) in enumerate(examples):
551       if ex_index % 10000 == 0:
552         tf.logging.info("Writing example %d of %d" % (ex_index, len(examples)))
553       # 对每个样本制作feature
554       feature = convert_single_example(ex_index, example, label_list,
555                                        max_seq_length, tokenizer)
556
557       def create_int_feature(values):
558         f = tf.train.Feature(int64_list=tf.train.Int64List(value=list(values)))
559         return f
560
561       features = collections.OrderedDict()
562       features["input_ids"] = create_int_feature(feature.input_ids)
563       features["input_mask"] = create_int_feature(feature.input_mask)
564       features["segment_ids"] = create_int_feature(feature.segment_ids)
565       features["label_ids"] = create_int_feature([feature.label_id])
566       features["is_real_example"] = create_int_feature(
567           [int(feature.is_real_example)])
568
569       tf_example = tf.train.Example(features=tf.train.Features(feature=features))
570       writer.write(tf_example.SerializeToString())
571     writer.close()
```

模型：

> 刚开始num_warmup_steps次迭代学习率偏小，之后恢复设置的学习率

构建Embedding层===>

词向量编码（和变换维度）+位置和段从属关系嵌入（相加）+层归一化（和dropout）

构建Transformer层（encoder，自注意机制）===>

词向量扩维（目的是为了使每一个词对应每一个句子；同时创建mask标记有效性，即实现自注意）+多头机制（每个头专注于N种特征/输出的提取，后面是对每一个头的处理）+Q矩阵初始化（len(输入)xlen(特征)）+K矩阵初始化（len(输出)xlen(特征)）+V矩阵初始化（len(输出)xlen(特征)）+QK内积（接着结合mask标记运算，类似于单神经网络）+结果与V内积+（池化+训练等）

分词

```
嘉宝 20471
数量 16098
米粉 14468
营养 13848
单价 9770
小计 6091
原价 5995
收银员 5990
金额 5892
店 5773
合计 5698
品名 5465
元 5194
商品 5142
电话 4547
找零 4245
实收 4232
谢谢惠顾 4063
营业员 4005
现金 3863
号 3827
货号 3806
配方 3599
付款 3474
时间 3461
单号 2769
```

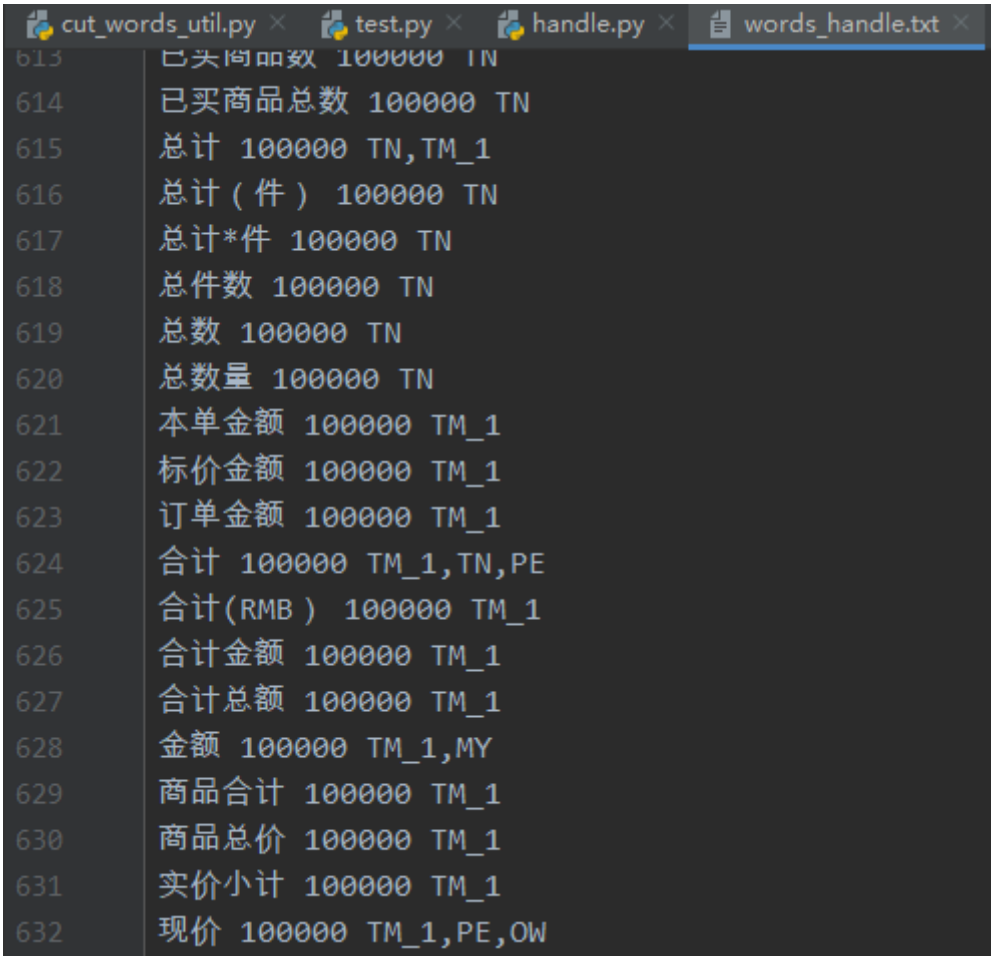

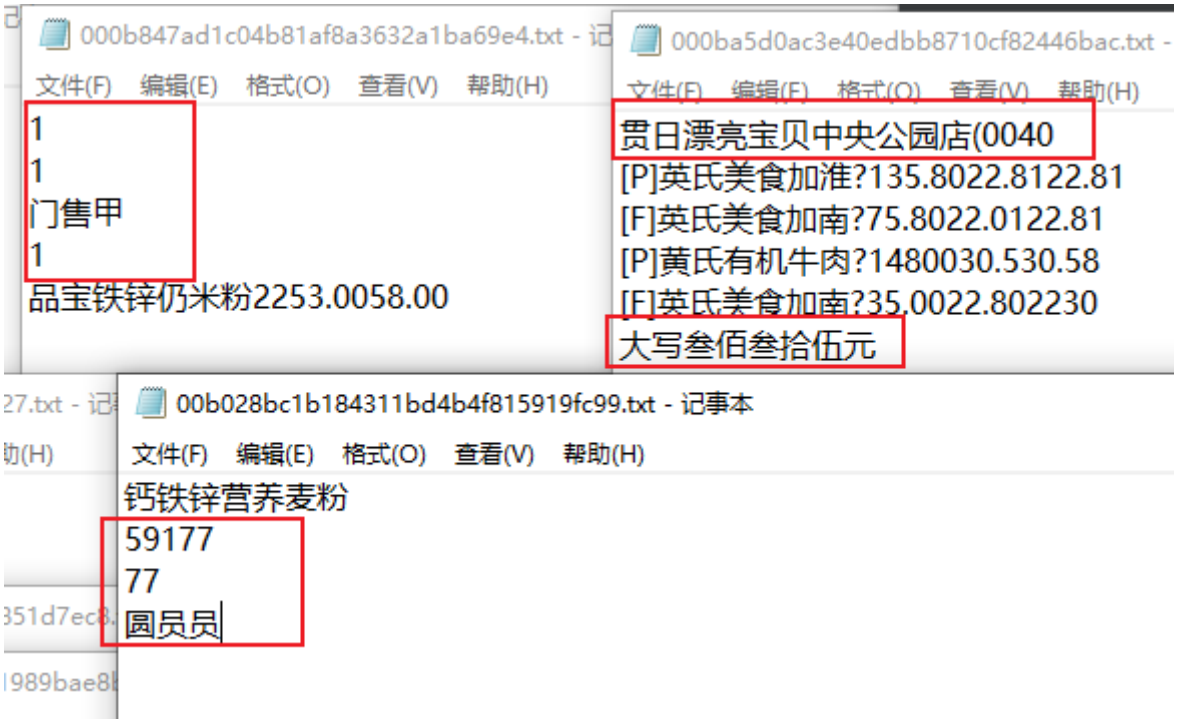

附：

> 分布相似性==>密集型向量；与词汇相对位置无关

skip-gram：利用中心词来预测上下文。

1、利用one-hot编码将单词转换为向量，维度为[1, V]（V一般表示总次数）

2、与权重向量W[V, N]（N是上下文窗口）点积运算，无激活函数，最后得到v个向量H[1, N]（相对每一个上下文词都会生成一个向量）

3、与输出层权重向量W'[N, V]点积得到向量U[1, V]，再经过softmax函数得到one-hot编码形式的预测向量。概率最大的那个单词就是结果，若预测有误，会通过反向传播算法来修正权重矩阵W和W'。